

# 实验 4 与实验 5：研究总报告

## 目录

|                    |    |
|--------------------|----|
| 1. 结论先行            | 1  |
| 2. 比较协议与可信基线       | 2  |
| 3. 最有用的结果对照        | 3  |
| 4. 各方向的结果、优点与疑问    | 3  |
| 5. 执行中遇到的问题与已完成的排查 | 14 |
| 6. 尚未回答的研究问题       | 15 |
| 7. 论文与交付状态         | 15 |
| 8. 工作区清理与保留内容      | 16 |
| 9. 暂停与恢复入口         | 17 |
| 附录：证据与文件导航         | 17 |

整理日期：2026-09-14。状态：当前实验结束，结果归档与清理完成，按要求暂停。

## 1. 结论先行

本轮最值得保留的是几类有边界的正面结果与一套可信比较记录，尚未得到“在相同权限下稳定胜过强基线、且可跨独立数据集推广”的新方法。更复杂的权重、训练目标、局部描述子或更大编码器，多次带来局部改善，但未满足各自预先设定的稳健标准。

1. **实验 5 的低成本中心化有可信小收益。**在原始规范比较中，单样本宏平均由 72.7733% 提高到 73.1333%，配对增益 0.3600 个百分点；在同数据集的新图像池上仍有 0.3250 个百分点改善。不过收益不均匀，且中心化不是新算法。
2. **真实多视图与散度是较有价值的开发域方向。**在另一套六视图、已用于开发的固定任务中，累积方案达到 77.374%；相对同视图均值 R2 提高 2.1653 个百分点，相对均值 CS 提高 1.8340 个百分点。增益主要来自 EuroSAT，不能与上一条 72.7733% 的不同协议直接相减。
3. **独立域强对照没有被稳定超越。**Caltech 上两个冻结累积配置为 98.0320% 和 97.9787%，低于增强支持岭回归 98.3307% 和 C10 逻辑回归 98.3920%。原数值审计失败及后续修复均保留；修复没有改变“缺乏强对照优势”的判断。
4. **最后一轮更强编码器没有通过升级标准。**DINOv2-B 候选均值 77.598%，旧方案 77.374%；差值 +0.2240 个百分点，95% 条件区间 [-0.0700, 0.5240]，既未达到 0.5 门槛，下界也未大于零。因此不把最高点估计当成稳健新方案。
5. **实验 4 仍有域内潜力，但本轮桥接几何未得到整体提升。**mAP43.0543 对 44.3259；DTD 改善而 EuroSAT 下降。保留这一域差异，拒绝把事后参数诊断写成新成功。
6. **论文线最清楚的是一条诊断发现。**图库样本“排序较好”不等于累计权重有益；任务外类别可能仍占据大部分影响。现有 OSLO 技术短文围绕这一窄结论，尚不是可投稿完成包。

## 阅读范围与计数

本报告逐项覆盖当前工作区全部 32 个主研究目录，整合 45 个方法与分析条目，包括原论文账本的 42 条及未纳入该账本的残差描述子、特征重构、DINOv2-B 三项。另将精度修复、错误互补、参数选择不稳定与执行问题放入专节。441 条去重归档记录只是本次读取的管理记录快照，包含重复汇报与状态记录，不等于 441 个实验；45 个条目也不等于 45 次独立复现。

本报告为面向项目负责人的证据与问题汇总，不是将全部历史实验强行拼接成同一篇论文。局部正收益、独立测试失败、已有方法与特权诊断在下文分别标明。

## 2. 比较协议与可信基线

### 2.1 历史材料如何复用

最初实验 5 仅在 DTD 五样本、原三个种子的 600 任务上得到独立重放：90.1533%，原记录 90.1489%，相差 0.0044 个百分点。这一近似重放只支持该切片，原 16 行历史结果保留为参考，不代表全部已复现。历史完整逐任务预测或排名缺失，不能仅凭汇总表补造统计区间。

实验 4 历史 CUB64 桥接方向有 mAP65.85 对 62.51 的局部记录，但 oracle 保留率 39.12% 未达到 50% 目标。它不是本次 DTD/EuroSAT 规范检索的新证据。初始专项核心快照 1406 个文件哈希匹配，只证明该核心快照一致；完整预测、排名不在该快照中。

### 2.2 三套规范比较各自保留

| 比较范围                 | 基线核心值                           | 可支持什么                    | 不能混同什么                   |
|----------------------|---------------------------------|--------------------------|--------------------------|
| 原始 DTD/EuroSAT 单视图分类 | R2 宏平均 72.7733%                 | 同冻结特征、同任务、四单样本条件及五样本守护比较 | 六视图新开发协议、Pets 分数         |
| DTD/EuroSAT 语义桥接检索   | 旧空间中心化 mAP44.3259；V0 变体 43.3067 | 固定 32/64 桥接、同全图库排名比较     | 历史 CUB/Oxford 实例检索或 SOTA |
| Pets 冻结图库迁移          | 同域单样本 96.2400%，异域 93.9307%      | 同权限图库与支持集控制，五样本亦保留       | 原 SWAT/iLPC/OSLO 所有论文设定  |

Pets 五样本同域和异域 R2 均为 98.4427%，原因是其五样本头仅用支持集。两个相同图库条件不是独立证据；Pets 单样本宏平均 95.0853% 也不能与 DTD/EuroSAT 宏平均直接排行。

### 2.3 统计与权限边界

置信区间主要采用按原种子分层、任务配对的 bootstrap，条件于固定图像池。它们不是随机新域的置信区间，也没有自动包含反复研究选择造成的不确定性。图库条件共享任务时先在任务内平均；训练种子、任务种子、图库重复条件和独立图像池分别计数。

早期固定图库方法禁止查询批次适应；后期逐查询一致性允许单个查询及其视图参与特定计算，仍不使用整个查询批次或答案。两者权限不同。用真实图库类别作的组成过滤、oracle 选专家仅用于诊断，不能与可部署算法同列。预训练数据是否与目标语义或图片完全独立尚未获证；解码 RGB 去重不等于语义重复排除。

### 3. 最有用的结果对照

#### 3.1 已开发六视图协议内的公平累积比较

| 方法                | DTD (%) | EuroSAT (%) | 两域均值 (%) |
|-------------------|---------|-------------|----------|
| 原始单视图 R2, 仅作信息量参照 | 76.5853 | 70.3360     | 73.4607  |
| 六视图均值 R2          | 77.9520 | 72.4653     | 75.2087  |
| 六视图均值 CS          | 77.8133 | 73.2667     | 75.5400  |
| 增强支持集岭回归          | 76.7440 | 72.1573     | 74.4507  |
| 固定散度预测融合          | 78.0773 | 76.5907     | 77.3340  |
| 加逐查询一致性           | 78.1573 | 76.5907     | 77.3740  |

累积方案相对六视图均值 R2 为 +2.1653 个百分点, 区间 [1.9600,2.3640]; 相对六视图均值 CS 为 +1.8340, [1.6380,2.0214]。前一比较中 DTD 仅 +0.2053, EuroSAT+4.1253。表中单视图到累积方案的 +3.9133 包含额外编码信息, 不能宣称为等预算几何改进。

#### 3.2 最后完成的 DINOv2-B 对照

| 比较对象            | B 候选减对照 (百分点) | 95% 条件区间          |
|-----------------|---------------|-------------------|
| 原小编码器累积方案       | +0.2240       | [-0.0700, 0.5240] |
| 同 B 编码器均值 R2    | +2.3380       | [2.1493, 2.5194]  |
| 同 B 编码器均值 CS    | +2.0647       | [1.8840, 2.2494]  |
| 同 B 编码器支持集岭回归   | +3.5807       | [3.3373, 3.8287]  |
| 同 B 编码器逻辑回归 C1  | +4.2593       | [4.0093, 4.5207]  |
| 同 B 编码器逻辑回归 C10 | +3.8607       | [3.5960, 4.1340]  |
| 同 B 编码器增强支持岭回归  | +3.1847       | [2.9547, 3.4247]  |

该轮唯一未满足汇总优越性要求的比较对象是原小编码器累积方案; 各域点估计无害及四图库条件下界大于-0.5 的要求均满足。结论是“不足以升级这一固定配方”, 不是“更强表征一定无用”。

14,153 图像的六视图特征完成验证; 1,000 独特任务、2,000 图库任务条件、9 种方法的 1,350,000 条预测算术及 34 个区间通过复核。原串联审核只重建每条件的第 99 任务; 补充审核完成协议全部五个指定索引, 共 40 个方法-任务-条件独立代数案例, 最大绝对分数误差 1.4433e-15。逻辑回归优化器本身未独立重写。

### 4. 各方向的结果、优点与疑问

“优点”包括已测出的性能优势和有证据支持的诊断价值; 若只是合理动机, 会明确写成检验目的, 绝不当成已证实的收益。以下编号可在 evidence\_index.json 找到原始报告、数据和协议路径。

#### E01 支持集锚定的残差迁移

当前判断: 未通过。单样本宏平均 71.133%, R2 为 72.7733%; 差值-1.6403 个百分点, 区间 [-1.793,-1.491]。

值得保留的优点或价值: EuroSAT 异域图库局部提高 2.1307 个百分点, 说明收缩或残差处理可能缓和某些失配。

**问题与限制：** EuroSAT 同域下降 5.6267 个百分点；总体也落后支持集岭回归及质量匹配对照。五样本行为未改。  
**尚未解决：** 何种任务能获益尚无可靠选择器；局部收益不能抵消整体下降。  
**证据：** [E01 原始记录](#)。

## **E02 邻域适应与分类损失替换**

**当前判断：** 未通过。邻域逻辑回归 72.376%，比 R2 低 0.3973 个百分点，区间 [-0.4877,-0.3083]。  
**值得保留的优点或价值：** 统一训练权限后，直接检验分类损失与邻域分布是否互相促进，归因比单独换分类头更清楚。  
**问题与限制：** 比均值逻辑回归仅高 0.0167 个百分点；损失与邻域的交互为负，未形成方法优势。  
**尚未解决：** 失败属于这一固定损失、正则和邻域设置；不等于所有判别式头都失败。  
**证据：** [E02 原始记录](#)。

## **E03 支持集中心化与归一化几何**

**当前判断：** 条件性正收益。宏平均 73.1333%，比 R2 高 0.3600 个百分点，区间 [0.2603,0.4613]；比同预算调参 R2 高 0.3270。  
**值得保留的优点或价值：** 成本低，原始池与新图像复核均有小幅总体提升，是第一条可信改进。  
**问题与限制：** 增益高度依赖域和图库：EuroSAT 异域约 +2.0067，同域约-0.3693；DTD 异域约-0.208。中心化本身是已知方法。  
**尚未解决：** 收益究竟来自检索还是分类几何，需要结合因子分解；不能宣传普遍鲁棒或新算法。  
**证据：** [E03 原始记录](#)。

## **E04 仅支持集的预验证岭回归选择**

**当前判断：** 局部有效、归因收窄。五样本 DTD89.852%，EuroSAT89.5053%；相对开发集调参原始岭回归两域均值提高 1.284 个百分点。  
**值得保留的优点或价值：** 无需查询标签，可在支持集内部选择正则与输出尺度，EuroSAT 改善明显。  
**问题与限制：** 相对 PRESS-MSE 只提高 0.0213 个百分点，区间 [-0.0127,0.0547]；继承的单样本 73.1333% 不是本次创新带来的。  
**尚未解决：** 强固定正则能否解释大部分收益？后续固定惩罚与多数据集实验已经显著削弱独特性。  
**证据：** [E04 原始记录](#)。

## **E05 图库样本独占归属**

**当前判断：** 未通过。宏平均 72.785%，比 R2 高 0.0117 个百分点，区间 [-0.1153,0.1383]；比中心化对照低 0.3483。  
**值得保留的优点或价值：** 可解释地限制同一样本对多个类别重复贡献；对照隔离了数量与总权重因素。  
**问题与限制：** 总体提升不成立，对若干较弱控制的改善不能替代对强方案的胜出。

**尚未解决：**去重是否只对特定混淆图库有用尚未建立。

证据：[E05 原始记录](#)。

## **E06 岭回归前后融合位置**

**当前判断：**小幅收益、强门槛未过。晚期融合 72.9803%，比 R2 高 0.2070 个百分点，区间 [0.1257,0.2893]；比中心化对照低 0.1530。

**值得保留的优点或价值：**在共享检索、相同开发预算下，明确区分特征融合与预测融合，存在可复核的小增益。

**问题与限制：**收益未超过已有中心化方案，不能将融合位置包装成新的领先方法。

**尚未解决：**不同表征的互补性是否能在不引入选择偏差的条件下利用，仍需独立任务证据。

证据：[E06 原始记录](#)。

## **E07 实验 4：桥接残差的插值几何**

**当前判断：**未通过。主候选 mAP43.0543，对照 44.3259；差值-1.2716 个百分点，区间 [-3.0398,0.6856]。

**值得保留的优点或价值：**DTD 提高 2.1096 个百分点，保留了跨编码器桥接方向在特定域的潜力。

**问题与限制：**EuroSAT 下降 4.6527；等强度几何差值 0.4138 区间仍包含零。未复现历史 CUB/Oxford 实例检索结论。

**尚未解决：**域间符号相反的机制未被确定；不能凭事后较小插值强度重新宣称成功。

证据：[E07 原始记录](#)。

## **E08 Pets 独立数据集上的 iLPC 式迁移**

**当前判断：**未通过。同域单样本 96.0533%，R2 为 96.2400%；异域 58.5573%，比 R2 低 35.3733 个百分点。

**值得保留的优点或价值：**同域比支持集 C10 逻辑回归高 1.7200 个百分点，证明合适图库可能有信息价值。

**问题与限制：**未胜过同权限图库强对照；异域 500/500 任务受损，五样本同域与异域也落后。

**尚未解决：**标签传播或逐步选样在严重图库失配时如何避免错误累积，尚无合格补救。

证据：[E08 原始记录](#)。

## **E09 图库专用开放集原型拟合**

**当前判断：**主方法未通过、诊断有价值。在标准 Pets 池与事先保留的新图像池，共八个条件均低于 R2；标准同域单样本 94.9173%，R2 为 96.24%。

**值得保留的优点或价值：**将原型更新、开放集评分与独立图库权限明确分离，提供了可复核的失败案例。

**问题与限制：**这是本地图库迁移版本，不是原论文全部设定的复现或反证；不能利用查询集适应来补救同一权限下的结果。

**尚未解决：**为何较好的域内排序不能带来有益更新，是现有技术短文最清楚的问题。

证据：[E09 原始记录](#)。

## E10 源域相关性校准与图库先验适应

当前判断：未通过。预先设定的双向迁移标准未通过；估计先验易向 0 或 1 坍缩，未建立样本组成收益。

值得保留的优点或价值：把排序、校准和先验变化拆开，避免只用 AUROC 判断图库可用性。

问题与限制：源域上能拟合的相关性不保证目标域权重可用；这是开发域研究，不是新增独立 Pets 确认。

尚未解决：先验不可识别、条件分布改变和校准误差各占多少，仍未完全分离。

证据：[E10 原始记录](#)。

## E11 直接学习任务效用权重

当前判断：未通过。相对训练标量控制，两个方向单样本分别-0.1760 和-1.4827 个百分点；等混合强度比较为+0.0533 及-1.2267。

值得保留的优点或价值：直接优化分类效用，比单纯判别是否同类更贴近最终任务，且控制了混合强度。

问题与限制：正向等强度小增益的区间包含零，反向显著受损；8 条件、4000 任务条件复核未挽回结果。

尚未解决：有用样本是否能由现有冻结特征稳定识别，还是训练分布覆盖不足，未被本方法解决。

证据：[E11 原始记录](#)。

## E12 源图库覆盖与自适应权重因子实验

当前判断：未通过。混合覆盖对标量控制有小幅作用，但未救活类自适应影响候选；完整 48 模型、8 条件结果保留。

值得保留的优点或价值：把训练覆盖与模型能力分开，发现原先源任务缺少完全外部图库，避免误归因于权重公式。

问题与限制：覆盖改善不等于自适应机制有效；不能凭增加训练情景宣称更稳健。

尚未解决：更真实的失配覆盖是否足以支持另一种机制，仍是开放问题，当前不继续训练。

证据：[E12 原始记录](#)。

## E13 真实多视图与支持集散度几何

当前判断：条件性收益、原审计缺口保留。六视图均值在八条件均改善原表征；散度在 EuroSAT 单样本比均值 R2 高 3.4547 个百分点，在 DTD 仅高 0.0640。

值得保留的优点或价值：最明确的正面发现是更多真实视图有用；散度在 EuroSAT 还提供额外收益，且种子方向一致。

问题与限制：DTD 强控制门槛未过；原 88 项端到端检查有 1 项浮点邻居并列失败，不得改写为原审计全通过。

尚未解决：域差异来自几何、视图内容还是图库构成尚未确定；独立精度复核只缩小数值疑虑，不证明泛化。

证据：[E13 原始记录](#)。

## E14 保留整组视图分布的核分类

**当前判断：未通过。**相对同预算均值 RBF，两个方向只提高 0.0747 和 0.0667 个百分点；相对均值 R2 下降 1.9960 和 1.2853。

**值得保留的优点或价值：**检验了视图两两信息是否优于简单平均，数学极限与独立代数检查完整。

**问题与限制：**未达到双向 0.5 个百分点门槛；核方法已有先例，此结果不能提供新颖性。

**尚未解决：**保留视图分布为何不带来可用信息，可能涉及核尺度和表示质量，但本轮不做事后扩网格。

证据：[E14 原始记录](#)。

## E15 先非线性变换还是先平均

**当前判断：未通过。**前置变换相对后置平均的两个方向差值为-0.1573 与 +0.1707 个百分点；相对冻结线性均值两方向单样本约低 4.8 及 4.7。

**值得保留的优点或价值：**参数量、训练任务、标签与初始化匹配，能较干净地比较聚合顺序。

**问题与限制：**一方向三个训练种子全负；另一方向均值小且种子不稳定，源域训练优势未迁移。

**尚未解决：**学习到的变换是否过度专门化、哪些训练目标能避免损失，仍未解。

证据：[E15 原始记录](#)。

## E16 减少视图的成本与精度折中

**当前判断：未认证替代方案。**两个源域都选择六视图回退，实际选定策略成本比为 1；没有认证三视图替代。

**值得保留的优点或价值：**明确测量编码应用数和本机时间，展示了压缩视图的实际折中。

**问题与限制：**最接近的三视图规则虽然均值损失小于 0.5，但最差下界约-0.5467 或-0.6800，越过预设容忍线。

**尚未解决：**是候选集合不够好还是 100 源任务不足以认证非劣，需要区分；不能说所有少视图方案都失败。

证据：[E16 原始记录](#)。

## E17 相同训练预算下的源数据混合

**当前判断：局部改善、总体未通过。**36 次拟合中，混合源相对原源两个方向提高 0.6329 和 0.8889 个百分点，但比零训练参考低 0.8951 和 5.1778。

**值得保留的优点或价值：**训练数据组成确实改变迁移效果；比增加模型复杂度更直接地检验数据问题。

**问题与限制：**优于弱训练方案仍低于不训练，无法证明适配值得做；这轮实际为单视图，旧成本措辞已更正。

**尚未解决：**为什么源验证改善而目标变差、何时不适配更好，是重要未解问题。

证据：[E17 原始记录](#)。

## E18 任务级 CLIP/DINO 表征选择

**当前判断：未通过。**任务内选择在两个开发域都低于固定等权表征。

**值得保留的优点或价值：**无需新增编码器，可检验是否应按任务选择互补表征。

**问题与限制：**支持集太少时选择信号不足；现有结果更支持保留稳定的固定组合。

**尚未解决：**选择失败是信号不足还是准则与最终分类头不对齐，需要后续支持验证实验共同判断。

证据：[E18 原始记录](#)。

## **E19 与分类头对齐的支持集验证选择**

**当前判断：**未通过。单样本和五样本的主选择器都低于固定表征方案。

**值得保留的优点或价值：**针对上一轮选择准则偏离分类目标的问题进行了更直接的检验。

**问题与限制：**对齐分类头仍未可靠选出更优表征，不能把此前失败仅归因于一个评分公式。

**尚未解决：**极少支持标签是否从信息上不足以作稳定选择，当前证据尚非不可能性证明。

证据：[E19 原始记录](#)。

## **E20 中心化与散度的累积组合**

**当前判断：**条件性收益。开发单样本均值比均值 CS 高 1.648 个百分点；但与散度单独比较时域或条件门槛失败。

**值得保留的优点或价值：**遵循在当前较好方案上叠加的思路，减少从弱基线反复获得表面提升。

**问题与限制：**总收益包含已有散度部分；不能把组合的全部提高都归于中心化新贡献。

**尚未解决：**两者互补在哪些任务发生，需要看后续预测融合及因子归因。

证据：[E20 原始记录](#)。

## **E21 固定预测融合**

**当前判断：**小幅条件性收益。等权融合达到 77.334%，比散度 CS 提高 0.146 个百分点，低于 0.5 门槛。

**值得保留的优点或价值：**使用已有专家输出即可获得小幅增益，额外开销较小，保留了可用的条件性方案。

**问题与限制：**提升幅度不足以单独支撑强改进；不代表独立目标域领先。

**尚未解决：**专家错例互补是否能被无标签规则利用，后续 oracle 与选择器分别检验。

证据：[E21 原始记录](#)。

## **E22 类别关联的支持视图几何**

**当前判断：**未通过。准确率 77.3187%，比 77.334% 父方案低 0.0153 个百分点；累积与类别关联门槛均未过。

**值得保留的优点或价值：**显式利用视图和类别关联，检验了仅整体散度可能丢失监督结构的假设。

**问题与限制：**未转化为稳定分类收益，不能以机制合理替代指标证据。

**尚未解决：**是类信息太少还是校正重复了已有信息，尚无定论。

证据：[E22 原始记录](#)。

## E23 源域训练的逐查询专家选择

当前判断：未通过。77.2753%，比固定融合低 0.0587 个百分点，区间 [-0.1033,-0.0133]；修复 473 例却破坏 561 例。

值得保留的优点或价值：明确量化选择器的修复与破坏，能解释为什么存在 oracle 空间仍会总体退步。

问题与限制：源训练选择分数没有学到足够稳定的可迁移判别能力。

尚未解决：可观测的无标签可靠性信号与 oracle 差距仍未解决。

证据：[E23 原始记录](#)。

## E24 逐查询视图一致性

当前判断：极小条件性收益。77.374%，比固定融合高 0.0400 个百分点，区间 [0.0140,0.0673]；DTD+0.08，EuroSAT 不变。

值得保留的优点或价值：逐查询处理，不用整个查询批次；在已累积方案上仍有小的可复核增益。

问题与限制：低于 0.5 门槛，推理权限也不同于早期图库专用 OSLO 方案；不能直接跨协议比较。

尚未解决：改进是否能跨独立域稳定存在，Caltech 检验未支持强对照优势。

证据：[E24 原始记录](#)。

## E25 图库局部密度归一化

当前判断：未通过。77.2687%，比 77.374% 父方案低 0.1053 个百分点，区间 [-0.1867,-0.0233]。

值得保留的优点或价值：检验局部参考分布和高密度偏置，避免只修改类别权重。

问题与限制：完整预测和独立区间复核后仍为负，固定密度配方不应保留。

尚未解决：密度估计与真正有用性之间的差异尚未解决。

证据：[E25 原始记录](#)。

## E26 DINO 局部描述子匹配

当前判断：未通过。局部匹配融合 75.786%，比父方案低 1.588 个百分点，区间 [-1.8067,-1.3660]。

值得保留的优点或价值：使用空间局部信息挑战仅 CLS 全局向量的瓶颈假设，存在少量局部独有正确例。

问题与限制：局部独有正确 6699 例，父方案独有正确 18542 例；与局部均值融合仅差 +0.034，区间含零。

尚未解决：局部信号如何筛选而不破坏更强全局表示，未有可部署选择器。

证据：[E26 原始记录](#)。

## E27 逐图像残差化局部描述子

当前判断：未通过。69.0713%，比 77.374% 父方案低 8.3027 个百分点，区间 [-8.6520,-7.9393]；两个域均明显下降。

值得保留的优点或价值：直接检验去掉共享全局成分能否突出有用局部差异，反例很有区分力。

**问题与限制：**残差化可能同时删掉有用信号；这里是测量结论，具体原因仍属解释假说。

**尚未解决：**不能以“局部更专一”作为保留理由，也不应继续事后调整混合比例挽救。

**证据：**[E27 原始记录](#)。

## **E28 支持类别特征重构**

**当前判断：未通过。**重构融合 75.3233%，比父方案低 2.0507 个百分点，区间 [-2.2860,-1.8080]；比秩 1 控制仅高 0.0073，区间含零。

**值得保留的优点或价值：**保留原始描述子，测试类子空间重构，和删除共享信号的残差化结构不同。

**问题与限制：**没有证明完整子空间比简单低秩控制有用；不是原 FRN 训练方案的完整复现。

**尚未解决：**额外空间信息如何获得稳定类别约束仍待解决，当前不训练或扩展该家族。

**证据：**[E28 原始记录](#)。

## **E29 相对参考的源组最差风险训练**

**当前判断：未通过。**相对最差组风险比匹配均值训练有所改善，但相对恒等映射两个方向为 +0.0827 和 -1.0213 个百分点。

**值得保留的优点或价值：**同时控制训练目标与选择规则，检验平均风险是否掩盖困难源组。

**问题与限制：**目标更强仍未超过不变换的强参考，且双向不稳健。

**尚未解决：**优化源组目标能否预示未知域的收益，当前证据为否定这一固定配方。

**证据：**[E29 原始记录](#)。

## **E30 与最终头对齐的有限视图训练目标**

**当前判断：未通过。**最差视图候选在 DTD72.7467%、EuroSAT74.2418%；相对散度参考低 5.3307 和 2.3489 个百分点。

**值得保留的优点或价值：**把真实视图、检索及最终分类头纳入同一目标，避免只追求与评估无关的代理损失。

**问题与限制：**对弱损失控制的小改善未弥补对强冻结方案的损失。

**尚未解决：**明确目标对齐也不足以保证迁移，可能需要不同监督或训练任务结构，但本轮未证明。

**证据：**[E30 原始记录](#)。

## **E31 冻结 DINO 多层深度读出**

**当前判断：未通过。**相对最终层一致性方案，DTD-3.3400、EuroSAT+0.9813；总体-1.1793 个百分点，区间 [-1.4073,-0.9546]。

**值得保留的优点或价值：**不用训练编码器，从不同深度读取信息，在 EuroSAT 有可见局部收益。

**问题与限制：**固定多层融合损害 DTD，总体门槛失败；不能根据这些结果回头选择层或权重。

**尚未解决：**域差异意味着深层与中层信息用途不同，尚未形成无标签可靠选择机制。

**证据：**[E31 原始记录](#)。

### E32 更强 DINOv2-B 与同步加强的控制

当前判断：未通过升级。77.598% 对 77.374%，仅 +0.2240 个百分点，区间 [-0.0700,0.5240]；相对同编码器均值 CS 仍 +2.0647。

值得保留的优点或价值：证明已有散度配方在更强表征下仍可优于简单头；全部视图、图库权限与控制同步。

问题与限制：未满足对原方案至少 0.5 且下界大于零的标准；不同预训练权重和计算量不能解释为纯容量因果效应。

尚未解决：更强编码器的实用提升是否值得额外计算尚不确定；这轮完成后按要求暂停。

证据：[E32 原始记录](#)。

### E33 中心化方案的新图像确认

当前判断：同域新图像复核有效。在原数据集的新图像池上，72.590% 对同池 R2 的 72.265%，+0.3250 个百分点，区间 [0.2280,0.4237]。

值得保留的优点或价值：零解码 RGB 重叠，证明早期小收益并非仅在原批图像中存在。

问题与限制：仍是相同数据集与原图库，增益不均；不能称为未知域确认。

尚未解决：独立域收益必须另测，不能用更多同域任务代替。

证据：[E33 原始记录](#)。

### E34 检索与分类头的因子归因

当前判断：诊断有效。单样本组合 +0.3600，检索单独 +0.1330，分类头单独 +0.3177，交互-0.0907 个百分点。

值得保留的优点或价值：发现分类几何贡献更大且组合非简单相加；五样本半径控制可超过完整中心化。

问题与限制：这些是固定池条件效应，不是对所有检索模型的一般定律。

尚未解决：中心化收益与正则尺度变化之间的关系需用强尺度控制解释。

证据：[E34 原始记录](#)。

### E35 跨编码器的岭回归尺度控制

当前判断：条件性有效。半径缩放在四个融合条件都优于 CS；但相对等调参全局岭回归，在四个 CLIP 条件全部为负。

值得保留的优点或价值：揭示正则强度与表示尺度的重要性，避免把数值尺度收益误称为新的几何机制。

问题与限制：不同编码器符号相反，没有普适优越性。

尚未解决：应优先建立等调参的简单岭回归对照，不能只比固定惩罚 1。

证据：[E35 原始记录](#)。

### E36 PRESS 与全部固定惩罚比较

当前判断：削弱自适应独特性。四个融合条件相对固定 0.001 的差值仅约 0.0187 至 0.0293 个百分点，区间都包含零。

值得保留的优点或价值：用完整固定网格挑战自适应选择，避免只挑较弱常数。

问题与限制：早期相对惩罚 1 的提升大部分可由更好的固定正则解释。

尚未解决：是否仍有无需开发标签的便利性可以保留，应与独立精度优势分开。

证据：[E36 原始记录](#)。

### E37 CUB、Flowers 和 CIFAR-FS 扩域验证

当前判断：未见 PRESS 普适优势。九条件都未支持 PRESS 胜过开发集调参固定岭回归；融合相对固定 0.001 仅约 0 或 0.0013 个百分点。

值得保留的优点或价值：提供三个额外数据集及 CLIP/DINO/融合对照，检验原域结论外推。

问题与限制：高准确率天花板与编码器差异限制可检测空间；81 数值行不是 81 独立实验。

尚未解决：不能由近似持平推断等效，也不能将局部好结果推广到所有细粒度任务。

证据：[E37 原始记录](#)。

### E38 强逻辑回归控制

当前判断：校准对照价值。21 条件与调参岭回归比较：5 个正、8 个负、8 个区间含零；不是多重校正的全局检验。

值得保留的优点或价值：表明固定 C1 常欠校准，避免用弱逻辑回归对照制造虚假领先。

问题与限制：不存在广泛逻辑回归优势；EuroSAT 融合仍低于强固定岭回归。

尚未解决：正则选择权限必须匹配，域别点估计不可替代统一结论。

证据：[E38 原始记录](#)。

### E39 图库限制下的 iLPC-z 强方法对照

当前判断：局部收益、失配严重。单样本宏平均 60.3897%，R2 为 72.7733%；EuroSAT 同域单样本 +13.648，但两类失配约 -31.3133 与 -24.212。

值得保留的优点或价值：同域有大幅收益，证明图库传播在适合的分布中并非无效。

问题与限制：低于整体强基线，DTD 同域也明显受损；受限图库版本不能代指原方法所有实验。

尚未解决：如何判断图库适用性是关键，后续 Pets 失败加强了边界证据。

证据：[E39 原始记录](#)。

## E40 OSLO 的排序与累计权重诊断

当前判断：支持窄机制结论。同域单样本 inlier AUROC 约 0.93，但约 80% 保留图库权重来自任务外类别。

值得保留的优点或价值：清楚揭示排序分数好不等于总更新有益，是技术短文最有价值的观察。

问题与限制：不能由排序相关性直接宣称因果机制已被完全解释。

尚未解决：类别基数、权重总量与组成各占多少，需要干预来分离。

证据：[E40 原始记录](#)。

## E41 最终更新的质量与组成干预

当前判断：支持诊断、非可部署方案。质量平衡可大幅救回失配，但仍损害同域单样本；使用真实类别信息过滤组成可改善同域。

值得保留的优点或价值：分别干预总质量和组成，说明只控总量不足以解决所有问题。

问题与限制：组成过滤用了额外真实信息，只能作特权诊断，不能记作合规算法成绩。

尚未解决：如何在无图库标签条件下逼近有用组成，仍未解决。

证据：[E41 原始记录](#)。

## E42 累积几何的再归因

当前判断：诊断有效。固定检索与几何分解显示域依赖，未有简单混合在所有条件建立更强补救。

值得保留的优点或价值：解释累积增益来自哪里，减少把父方案改进重复计入子方案。

问题与限制：解释性分析并未产生新的稳健方法。

尚未解决：是否存在能在少样本下识别的任务类型，当前选择实验未支持。

证据：[E42 原始记录](#)。

## E43 源映射几何畸变诊断

当前判断：否定简单代理解释。36 映射、13424 图像：目标 Gram 变化更大也可伴随更小迁移损失；一个 EuroSAT 例中误差 0.09769 到 0.13080 而损失 6.0667 降至 5.1778。

值得保留的优点或价值：提供了反例，防止仅因几何变化大就添加泛化保持惩罚。

问题与限制：观测关系不是因果；不否定所有选择性正则。

尚未解决：真正应保持的是哪些类别相关结构而非整个 Gram，尚无证据确定。

证据：[E43 原始记录](#)。

## E44 三专家 oracle 上界与选择空间

当前判断：仅诊断上界。oracle 79.2173% 对固定融合 77.334%，空间 1.8833 个百分点。

值得保留的优点或价值：证明专家错误有互补性，为是否值得试选择器提供量化依据。

问题与限制：oracle 使用答案判定正确专家，不是可部署准确率；随后的能力选择器反而退步。

**尚未解决：**可观察特征能否识别互补错误，是未被解决的核心差距。

证据：[E44 原始记录](#)。

## **E45 累积方案的 Caltech 独立域确认**

**当前判断：**强对照资格未通过。两个冻结配置 98.0320% 和 97.9787%；增强支持岭回归 98.3307%，C10 逻辑回归 98.3920%。

**值得保留的优点或价值：**提供独立域强控制检查，直接挑战开发源域局部最佳是否能推广。

**问题与限制：**原完整数值审计失败；后续浮点修复应独立陈列，不能把原记录改成功。

**尚未解决：**更高开发成绩没有转化为最强目标结果，仍缺稳健跨域证据。

证据：[E45 原始记录](#)。

## **5. 执行中遇到的问题与已完成的排查**

### **5.1 数值精度：相同预测不等于完整分数等价**

散度原审核 87/88 通过，DTD 源单样本第 99 任务在 `gamma0.1` 下有一个 `top64` 邻居因 `float32` 近并列而交换，完整分数误差约 0.003034 超过固定  $2e-5$ 。固定邻居后回归误差小、预测不变，只能定位问题，不能把原失败改成通过。

随后完整检查 1,200 个单样本源配置、90,000 个查询预测，保存 `float32` 与独立 `float64` 的预测计数和 `gamma` 选择均不变：DTD 选择 10，EuroSAT 选择 1。独立 `float64` 两种代数路径最大误差约  $2.03e-14$ ，原 `float32` 失败仍为同一例。数值选择稳定已经核实，只有两计数的开发领先是否对新任务稳定仍未知。

Caltech 的确定性 `float64` 控制修复使固定 15 个真实任务和 1 个合成任务通过，112,500 条保存预测未变；相对修复控制，两个配置差值分别 -0.0471 和 -0.1004 个百分点，仍无稳健优越性。原失败、诊断与修复作为三个证据层同时保留。

### **5.2 任务采样与泄漏检查**

源身份池对半划分时，DTD 每类最少 37 图像，一半可能只有 18 张，无法同时抽取 5 支持与 15 查询。实际曾在两项单样本条件之后失败；修正仅把源训练/选择的五样本查询数设为 13，目标仍 15，保留已完成单样本记录。该变更是可行性修复，不能将修复前后当作同一个未经修改的协议。

Pets 类别和 DTD 类别编号不能直接数值比较。新图像确认检查解码 RGB 身份重叠；Caltech 目标中的 500 任务跨三图库复用，只是 1,500 条件，不是 1,500 独立任务。任务出现次数、独特图片、类别和独立数据集均不混算。

Pets 失败覆盖也有具体证据：同域单样本 37 类中 21 类低于 R2，异域 37 类全受损；同域选入的图库样本约 80% 属于任务外类别，异域为 100%。分类头线性残差很小使纯求解器错误解释较不可信，但不能据此认定唯一建模原因。

### **5.3 表征与实现细节**

CLIP 激活与 DINO 实现差异促成新的规范特征变体；没有把旧缓存分数与新实现强行要求完全相等。MPS 位置插值采用经过实测的 CPU 回退；硬件支持 Metal 不直接视为软件路径可用。

EuroSAT 原图是 64×64，直接 Resize224 后做 FiveCrop224 会得到重复视图。实际采用不同尺度/裁剪，并显式记录视图与编码预算；视图个数增加并不是免费改进。局部 16 描述子的有效参与秩约 1.4，共享图像成分占约 84%；这只是几何观察，后续残差化的大幅下降说明删掉共享成分并未得到实用方法。

最后一轮分类直接入口曾在产生结果之前崩溃。通过已验证的依赖导入顺序与精确模块路径恢复，没有修改科学代码或参数；正式计算和后续审核均退出成功。原始错误与修复命令保存在 recovery.json 和运行日志。

## 5.4 选择不稳定、弱对照与元数据误导

实验 4 开发集对 alpha2 相对 alpha1 的偏好很小，配对区间重叠；bootstrap 最优频次不是泛化概率，不能事后改选 alpha1 宣称成功。逻辑回归 C1 或岭回归固定惩罚 1 可能是弱控制，必须与等调参简单控制比较。

某些自动摘要把负总体结果标成 “major”，或把最新候选称作 incumbent；这些是管理标签，不是科学判定。主张以逐任务文件、固定门槛和审计报告为准。论文 42 条账本中仅 4 组直接支撑 OSLO 短文，38 项是参考历史，不是 42 组独立支撑。

发生过 NumPy 整数 JSON 序列化错误、导入路径与配置修复、Git 分页等待、完成任务未及时登记、特征完成后约两小时未自动接上分类。修复与原失败均保留。后续应由一个可恢复的计算-检查链驱动，避免把模型继续生成消息当成作业调度器；本次已暂停，不再启动新链。

## 6. 尚未回答的研究问题

1. 何时图库真正有益？同数据集图库也可能大部分不属于当前五类；域相同不等于任务相关。缺少能稳定识别有益影响、同时不读图库标签的办法。
2. 为何多视图散度主要帮助 EuroSAT？已有中心化、目标函数、局部描述子和更强表征对照缩小了可能解释，但没有唯一因果归因。
3. 能否从专家互补中得到可部署选择器？oracle 空间 1.8833 个百分点是真实诊断，训练选择器却修坏多于修好；可观测可靠性信号仍是缺口。
4. 为什么源域优化会伤害迁移？混合源、最差组、视图对齐等目标改进弱训练对照，却不能稳定超过不匹配参考。未来需要明确的新信息或监督条件，不能继续无依据加正则。
5. 简单方法的优势能否推广？中心化与强正则在一些协议上有效，但独立域、少数类别、不同预训练覆盖和计算成本还不能统一概括。
6. 更大编码器是否值得？最后点估计提高 0.224 个百分点但区间包含零；当前不能证明性能收益抵得上编码成本，更不能推出容量因果规律。
7. 论文贡献是否足够？现有正收益大多基于已知组件或暴露开发集，跨域强基线资格未过。诊断短文有清楚现象，但不等于已经具备高水平投稿的新颖性与外部充分性。

MIV 式支持验证头作为结构不同的方向只完成了先前文献与输入需求核对，未在本任务产生新实验结果；接续评估已按本次暂停指令取消。需要训练编码器或引入类文本的直接方法不满足当前固定权限，属于适用范围排除，不属于测量失败。以上均是恢复后的候选问题，本次不安排继续运行。

## 7. 论文与交付状态

现有 OSLO 技术短文、LaTeX、PDF、证据账本和审阅记录保留。其中心是“排序质量与累计图库影响需分别检查”，不是所有 45 项历史都支持这一机制。新残差、重构和更大编码器结果在本总报告中完整呈现，没有临时改写原论文结论。

已有检查显示草稿可编译、引用和表格已有核对，但包类型仍为 draft\_checkpoint，缺少投稿包与完成清单；本报告不宣称论文投稿就绪。原有文章质量提醒、失败实验和未解问题全部保留。暂停是按用户要求形成稳定交付点，不

是对论文成功的认证。

## 8. 工作区清理与保留内容

- 清理完成时间：2026-09-14T08:59:07.105874+00:00。删除 2,681 个权重或可再生张量缓存文件；合计删除 913,379 个文件及 55 个已核实原图目录。大量文件来自工作树中的重复数据副本，不代表相同数量的独立资产。
- 删除文件的逻辑体积合计 23.30 GiB；实测可用空间由 11.68 增加至 25.49 GiB，释放 13.82 GiB。逻辑总量不等于实际释放量，二者不混报。
- 20,716 个结果、配置、源码和论文复核文件在清理前后逐文件 SHA256 一致，差异为 0。逐任务预测、完整分数、聚合统计、协议、错误日志和失败结论均保留。
- 原始外部用户材料、共享环境、用户目录下的公共模型缓存、Git 历史及 DeepScientist 运行状态未清理。少量用途混合的图库邻居特征档案和用于已完成输入一致性诊断的张量仍保留，具体列在 cleanup\_receipt.json 的 uncertain\_preserved 中；它们没有被冒称模型权重。
- 完整清理计划、删除权重哈希、目录路径/大小摘要、受保护文件哈希和执行回执均在本交付目录。没有做 Git 历史重写。

**清理后的能力边界：**可以继续核对保存的预测和统计结果，但不能承诺立即从原图重新编码或重训所有头。需要重新下载模型/数据或恢复缓存的命令与来源仍在原协议；重跑前必须按删除清单恢复所需输入。权重清理属于此次明确要求的存储取舍，不掩盖为“所有实验仍可零准备复现”。

### 8.1 磁盘空间究竟存了什么

“空闲约 25 GiB”表示还可以使用的空间，不表示 25 GiB 都是结果。后续整理结束时实测空闲为 27.75 GiB。启动记录约 40.9 GiB 空闲与现在之间的差值，不能全归为实验结果：版本历史、运行记录、文献及系统其他变化都包含在整个磁盘的变化中。

| 内容                    | 本次统计                            | 统计含义                                       |
|-----------------------|---------------------------------|--------------------------------------------|
| 实验及基线结果，连同受保护代码、配置和论文 | 3.46 GiB                        | 对 21,043 个路径按文件内容去重；是内容字节量，不是磁盘独占空间        |
| 上述文件的所有路径逻辑大小         | 14.55 GiB                       | 包含多工作树副本；不能与去重值相加                          |
| Git 版本对象              | 约 8.55 GiB                      | 压缩后的 8.51 GiB 包加 42.71 MiB 松散对象；不等于当前工作区结果 |
| 根运行目录中工作树以外的记录        | 1.68 GiB                        | 运行日志、对话归档、证据输出和运行环境记录的 du 快照               |
| 文献                    | 根目录约 0.33 GiB；工作树先前快照约 1.32 GiB | 论文等参考材料，也不是实验结果                            |

此外，26 个工作树内还有历史运行记录、基线说明与数据标注。先前工作树分类快照中嵌套运行目录约 3.62 GiB；它与内容去重结果采用不同计量方式，不把这些数字强行相加解释磁盘总差额。完整目录快照见 storage\_du\_snapshot.txt，统计口径见 storage\_breakdown.json。APFS 可能共享文件数据块；du 与文件大小不能给出每个副本的独占物理成本。

后续已将 5,271 个完全相同的保存结果路径合并为硬链接，全部 20,716 个原受保护文件重新核验无差异。合并的逻辑重复量为 8.80 GiB，实测额外释放仅 0.51 GiB。此前 8.82 GiB 是受保护文件的全部逻辑重复量，不是可回收磁盘空间；其中没有全部都执行链接合并。

Git 无损压缩额外实测释放 0.13 GiB，所有分支引用和 HEAD 保持一致；没有删除历史对象、使 reflog 到期或重写分支。因此，工作区权重清理不等于从历史提交彻底抹除所有旧权重。三个清理步骤各自前后观测合计增加空闲 14.46 GiB；阶段间系统另有变化，最终空闲不应简单用这个数字反推。

保留历史是为了保住结果来源与失败记录，没有声称剩余目录只包含最终分数表。今后若需要进一步缩小，应单独评估精简历史及运行归档，而不是继续删除可信结果。已合并的旧结果视为不可变文件；恢复时新实验写新路径，若确需修改旧路径，先复制为独立文件。

## 9. 暂停与恢复入口

本轮在“最新结果已审计、所有方向有报告、清理有回执”的状态暂停。无新候选、训练或目标评估等待自动启动。恢复需新的用户消息或/resume，并从这份总报告、evidence\_index.json、cleanup\_receipt.json 与 handoffs/CURRENT\_CHECKPOINT.md 读取最新状态。

恢复时先确定新问题和预算，再按所需路径恢复输入。默认不重跑已失败的权重/层/混合强度网格，不重复已完成的精度审核；只有新假设、实际实现错误或明确的新权限才重新打开相应方向。所有未证实的问题保留为问题，不预设下一轮一定成功。

## 附录：证据与文件导航

同目录文件：研究总报告.md（可编辑原稿）、研究总报告.html（浏览版）、研究总报告.pdf（便携版）、evidence\_index.json（逐方向来源）、cleanup\_receipt.json（清理回执）、deleted\_weight\_hashes.json（权重哈希）、protected\_results\_before.json（保留结果哈希）、review\_report.md（本报告审阅）、coverage\_validation.json（覆盖核验）。源实验结果留在各自原位置，未为了合并报告复制巨型预测银行。

关键补充原始报告：累积同身份比较位于 experiments/analysis/accumulated-stack-comparison-20260913；目标精度修复位于 caltech-control-precision-20260913；完整源选择精度核验位于 source-selection-precision-20260914。上述名称是检索线索，绝对路径与报告 SHA256 见 evidence\_index.json 及原始清理/运行记录。

本报告的研究结论来自本地文件、已保存日志和审计记录。原论文中的外部方法仅用于定位与权限比较，未将其公开表格分数当成本任务的可比实测值。